


SVM鸢尾花分类问题

能达到较好的分类效果，图片如下所示



```
1 bias:      -2.481
2 w:        [ 1.05517241 -1.06206897]
3 accuracy:  1.000
```

最终可以达到100%的识别率，weight与bias如上图所示

图中红蓝两色表示两种不同的鸢尾花种类，绿色点为支持向量

代码中注释确为本人手写

main函数如下

```
1 if __name__ == "__main__":
2     trainset = create_data()
3
4     # # save data as csv when first run
5     # with open("iris_data.csv", "w") as csvdata:
6     #     writer = csv.writer(csvdata, delimiter="\n")
7     #     writer.writerows(trainset)
8
9     features, labels = trainset[:, :2], trainset[:, -1]
10
11
12     model = SVM()
13
```

```

14     # Train model
15     model.train(features, labels)
16
17     # calculate accuracy
18     y_hat = model.predict(features)
19     acc = calc_acc(labels, y_hat)
20
21     print("bias:\t\t%.3f" % (model.b))
22     print("w:\t\t" + str(model.w))
23     print("accuracy:\t%.3f" % (acc))
24
25     showpoints(trainset, model.w, model.b)

```

1.数据获取

使用以下python库，其中svm为自定义SVM算法文件

```

1  """
2  * @author   孟子喻
3  * @time     2021.4.30
4  * @file     classify_iris.py
5  *          svm.py
6  """
7  import numpy as np
8  import pandas as pd
9  from sklearn.datasets import load_iris
10 from svm import SVM
11 import matplotlib.pyplot as plt

```

```

1  def create_data():
2      iris = load_iris()
3      df = pd.DataFrame(iris.data, columns=iris.feature_names)
4      df['label'] = iris.target
5      df.columns = ['sepal length', 'sepal width', 'petal length', 'petal
width', 'label']
6      data = np.array(df.iloc[:100, [0, 1, -1]])
7      for i in range(len(data)):
8          if data[i, -1] == 0:
9              data[i, -1] = -1
10         # print(data)
11         return data
12
13     # 初次使用时将数据以csv格式存储
14     # with open("iris_data.csv", "w") as csvdata:
15     #     writer = csv.writer(csvdata, delimiter="\n")
16     #     writer.writerow(trainset)

```

create_data 即为老师提供的数据生成函数，将其存入csv文件中供后续调用

2.使用SVM进行训练

我使用的svm代码结构参照了MIT的Lasse Regin Nielsen2015年所写的代码，其中有很多巧妙的设计，每一段代码都会有具体到课本公式编号的单独注释和解析

`_init_`

```

1 class SVM():
2     def __init__(self, max_iter=10000, kernel_type='linear', C=1.0,
  epsilon=0.001):
3         self.kernels = {
4             'linear': self.kernel_linear,
5             'quadratic': self.kernel_quadratic
6         }
7         self.max_iter = max_iter
8         self.kernel_type = kernel_type
9         self.C = C
10        self.epsilon = epsilon

```

根据不同的核函数实现线性与非线性支持向量机

最大迭代次数，超过将自动退出

选择核函数

C为惩罚参数，C越大对误分类的惩罚越大

设置允许差错的范围

把核函数 `kernel` 分为 `linear` 和 `quadratic` 两种

1. `linear`: 线性核函数，对输入直接求点积
2. `quadratic`: 平方核函数，对输入求点积的平方

其余参数意义见上述注释

kernel_linear&kernel_quadratic

```

1 # 定义核函数
2 def kernel_linear(self, x1, x2):
3     # 线性核函数
4     return np.dot(x1, x2.T)
5 def kernel_quadratic(self, x1, x2):
6     # 二次核函数
7     return (np.dot(x1, x2.T) ** 2)

```

train解读

```

1 # 初始化
2 n, d = x.shape[0], x.shape[1]
3 alpha = np.zeros((n))
4 kernel= self.kernels[self.kernel_type]
5 count = 0

```

取拉格朗日乘子初值alpha全为0

设置核函数

计算迭代次数

参考课本P149, 7.4.3 SMO算法, 第一步取拉格朗日乘子初值alpha全为0, 并设置核函数为线性 (由数据点分布得)

```

1 while True:
2     count += 1
3     alpha_prev = np.copy(alpha)          # 将alpha深拷贝
4     # print(alpha.shape)
5     # print(alpha)
6
7     for j in range(0, n):
8         i = self.get_rnd_int(0, n-1, j)    # 随机获取不同的i与
j, 得到两个优化变量
9         x_1, x_2, y_1, y_2 = x[i, :], x[j, :], y[i], y[j]    # 储存实例的特征和
标签
10        k_ij = kernel(x_1, x_1) + kernel(x_2, x_2) - 2 * kernel(x_1, x_2)
11        if k_ij == 0:                      # k_ij
12            continue                      # 保证两
个实例不同
13        alpha_prime_2, alpha_prime_1 = alpha[j], alpha[i]

```

随机获取两个变量的特征和标签并保证他们不同，选取alpha1和alpha2来做优化变量

```

1         (L, H) = self.compute_L_H(self.C, alpha_prime_2,
alpha_prime_1, y_2, y_1)
2
3         # print(L, H)
4         # 计算weight和bias
5         self.w = self.calc_w(alpha, y, x)
6         self.b = self.calc_b(X, y, self.w)

```

这里 `compute_L_H` 是用来计算alpha2的上下边界，这个边界对应两个拉格朗日乘子alpha1和alpha2的取值范围，即 $[0, C] \times [0, C]$ ，其中C为惩罚系数，alpha1和alpha2即被限制在这样一个正方形内，我们一开始先忽略这个取值范围求最优解，求得最优情况下的取值后再与边界比较

其中求新的alpha2的上下边界的函数 `compute_L_H` 实现如下：

```

1 def compute_L_H(self, C, alpha_prime_j, alpha_prime_i, y_j, y_i):
2     # 求alpha2所在对角线端点的边界，即alpha2的取值范围
3     # print(C, alpha_prime_j, alpha_prime_i, y_j, y_i)
4     if(y_i != y_j):          # 若非同类
5         return (max(0, alpha_prime_j - alpha_prime_i), min(C, C -
alpha_prime_i + alpha_prime_j))
6     else:                    # 若为同类
7         return (max(0, alpha_prime_i + alpha_prime_j - C), min(C,
alpha_prime_i + alpha_prime_j))

```

由最优化问题的对 α_1 和 α_2 的约束推得，即

$$\alpha_1 y_1 + \alpha_2 y_2 = \text{常数}$$

y_1 和 y_2 是否相同，便对应P144 图7.8的两种情况， α_1 与 α_2 的等式约束在平行于正方形的直线上，原因如以下3公式所示，其中k也是常数，通过约束把双变量下的最优化转换为单变量下的最优化

$$y_1 \neq y_2 \text{ 时, } \alpha_1 - \alpha_2 = k$$

$$y_1 = y_2 \text{ 时, } \alpha_1 + \alpha_2 = k$$

$$L \leq \alpha_2^{new} \leq H$$

如果 $y_1 \neq y_2$, 则

$$L = \max(0, \alpha_2^{old} - \alpha_1^{old})$$

$$H = \min(C, C + \alpha_2^{old} - \alpha_1^{old})$$

如果 $y_1 = y_2$, 则

$$L = \max(0, \alpha_2^{old} + \alpha_1^{old} - C)$$

$$H = \min(C, \alpha_2^{old} + \alpha_1^{old})$$

这两个 L 与 H 的取值由以上4式决定, 这里与0和C取max和min是为了裁剪保证不超出 α 的取值范围

接 `train` 函数, 然后是计算weight和bias

```
1 self.w = self.calc_w(alpha, y, X)
2 self.b = self.calc_b(X, y, self.w)
3
4 # 计算x_i, x_j的预测值与真实值的误差
5 E_i = self.calc_E(x_1, y_1, self.w, self.b)
6 E_j = self.calc_E(x_2, y_2, self.w, self.b)
```

`calc_b`和`calc_w`实现如下

```
1 def calc_b(self, X, y, w):
2     b_tmp = y - np.dot(w.T, X.T)
3     return np.mean(b_tmp)
4
5 def calc_w(self, alpha, y, X):
6     return np.dot(X.T, np.multiply(alpha, y))
```

然后是计算预测值与真实值之间的误差

```
1 E_i = self.calc_E(x_1, y_1, self.w, self.b)
2 E_j = self.calc_E(x_2, y_2, self.w, self.b)
```

`calc_E`实现如下

```
1 def calc_E(self, x_k, y_k, w, b):
2     # 求E, 即g(x)对输入x_k的预测值y_k与真实值之差
3     return self.decision_f(x_k, w, b) - y_k
4 def decision_f(self, X, w, b):
5     # 决策函数, 即对输入进行预测
6     return np.sign(np.dot(w.T, X.T) + b).astype(int)
```

对应课本P145公式7.105, 这里课本上写的复杂一点, 但是里边一些部分已经存为weight和bias了, 课本这里直接带换一下较好, `decision_f` 决策函数其实就是 $y = w \cdot x + b$

```

1      # 求出alpha2未经剪辑的解
2      alpha[j] = alpha_prime_2 + float(y_2 * (E_i - E_j))/k_ij
3      # 利用求出的L,H对alpha2进行剪辑
4      alpha[j] = max(alpha[j], L)
5      alpha[j] = min(alpha[j], H)
6
7      # 用alpha2反推alpha1
8      alpha[i] = alpha_prime_1 + y_1*y_2 * (alpha_prime_2 -
alpha[j])

```

这一步是正式计算 α_2^{new} ，求出取值后与前面求出的L和H边界点比较，取极大或极小值，**这里与L比较大，与H比较小**的思路比较巧妙，能省去判断（正常思路是如果大于H则取H，如果小于L则取L）

最后利用 α_1 和 α_2 的等式关系求出 α_1 ，这样优化变量的整个迭代思路就很明确了，主体部分完成

完整代码

```

1  from __future__ import division, print_function
2  import os
3  import numpy as np
4  import random as rnd
5  filepath = os.path.dirname(os.path.abspath(__file__))
6
7  class SVM():
8      def __init__(self, max_iter=10000, kernel_type='linear', C=1.0,
epsilon=0.001):
9          self.kernels = {
10              'linear': self.kernel_linear,
11              'quadratic': self.kernel_quadratic
12          }
13          self.max_iter = max_iter
14          self.kernel_type = kernel_type
15          self.C = C
16          self.epsilon = epsilon
17      def train(self, X, y):
18          # 初始化
19          n, d = X.shape[0], X.shape[1]
20          alpha = np.zeros((n))
21          kernel = self.kernels[self.kernel_type]
22          count = 0
23          while True:
24              count += 1
25              alpha_prev = np.copy(alpha)
26              # print(alpha.shape)
27              # print(alpha)
28
29              for j in range(0, n):
30                  i = self.get_rnd_int(0, n-1, j)
31                  x_1, x_2, y_1, y_2 = X[i, :], X[j, :], y[i], y[j]
32                  k_ij = kernel(x_1, x_1) + kernel(x_2, x_2) - 2 *
kernel(x_1, x_2)

```

```

33         if k_ij == 0:                                # k_ij
34             continue                                  # 保证两
个实例不同
35         alpha_prime_2, alpha_prime_1 = alpha[j], alpha[i]
36         # 求alpha2所在对角线端点的边界，即alpha2的取值范围
37         (L, H) = self.compute_L_H(self.C, alpha_prime_2,
alpha_prime_1, y_2, y_1)
38         # print(L, H)
39         # 计算weight和bias
40         self.w = self.calc_w(alpha, y, X)
41         self.b = self.calc_b(X, y, self.w)
42
43         # 计算x_i, x_j的预测值与真实值的误差
44         E_i = self.calc_E(x_1, y_1, self.w, self.b)
45         E_j = self.calc_E(x_2, y_2, self.w, self.b)
46
47         # 求出alpha2未经剪辑的解
48         alpha[j] = alpha_prime_2 + float(y_2 * (E_i - E_j))/k_ij
49         # 利用求出的L,H对alpha2进行剪辑
50         alpha[j] = max(alpha[j], L)
51         alpha[j] = min(alpha[j], H)
52
53         # 用alpha2反推alpha1
54         alpha[i] = alpha_prime_1 + y_1*y_2 * (alpha_prime_2 -
alpha[j])
55
56         # 检查是否超出误差允许范围
57         diff = np.linalg.norm(alpha - alpha_prev)
58         if diff < self.epsilon:
59             break
60
61         # 如果超出设定的最大迭代次数仍未求出最优解，则返回
62         if count >= self.max_iter:
63             print("Iteration number exceeded the max of %d iterations"
% (self.max_iter))
64             return
65         # 临输出前计算最终的weight和bias
66         self.b = self.calc_b(X, y, self.w)
67         if self.kernel_type == 'linear':
68             self.w = self.calc_w(alpha, y, X)
69         return count
70
71     def predict(self, X):
72         return self.decision_f(X, self.w, self.b)
73     def calc_b(self, X, y, w):
74         b_tmp = y - np.dot(w.T, X.T)
75         return np.mean(b_tmp)
76
77     def calc_w(self, alpha, y, X):
78         return np.dot(X.T, np.multiply(alpha,y))
79
80     def decision_f(self, X, w, b):
81         # 决策函数，即对输入进行预测
82         return np.sign(np.dot(w.T, X.T) + b).astype(int)
83
84     def calc_E(self, x_k, y_k, w, b):
85         # 求E，即g(x)对输入x_k的预测值y_k与真实值之差
86         return self.decision_f(x_k, w, b) - y_k

```

```

87
88     def compute_L_H(self, C, alpha_prime_j, alpha_prime_i, y_j, y_i):
89         # 求alpha2所在对角线端点的边界，即alpha2的取值范围
90         # print(C, alpha_prime_j, alpha_prime_i, y_j, y_i)
91         if(y_i != y_j):          # 若非同类
92             return (max(0, alpha_prime_j - alpha_prime_i), min(C, C -
alpha_prime_i + alpha_prime_j))
93         else:                    # 若为同类
94             return (max(0, alpha_prime_i + alpha_prime_j - C), min(C,
alpha_prime_i + alpha_prime_j))
95     def get_rnd_int(self, a,b,z):
96         i = z
97         cnt=0
98         while i == z and cnt<1000:
99             i = rnd.randint(a,b)
100            cnt=cnt+1
101        return i
102    # 定义核函数
103    def kernel_linear(self, x1, x2):
104        # 线性核函数
105        return np.dot(x1, x2.T)
106    def kernel_quadratic(self, x1, x2):
107        # 二次核函数
108        return (np.dot(x1, x2.T) ** 2)

```

3.可视化显示

最后的绘图函数也很简单了

```

1  def showpoints(data, w, b):
2      positive_x = []
3      positive_y = []
4      negative_x = []
5      negative_y = []
6      fig = plt.figure()
7      ax = fig.add_subplot(111)
8      for item in data:
9          if item[-1] == 1:
10             positive_x.append(item[0])
11             positive_y.append(item[1])
12          if item[-1] == -1:
13             negative_x.append(item[0])
14             negative_y.append(item[1])
15             ax.scatter(positive_x, positive_y, color="r")
16             ax.scatter(negative_x, negative_y, color="b")
17      x = np.arange(3, 7, 0.1)
18      y = []
19      for item in x:
20          y.append(-w[0]/w[1]*item - b/w[1])
21      ax.plot(x, y)
22      sup_vc = get_sup_vc(data[:, 0:2], w, b)
23
24      ax.scatter(sup_vc[0], sup_vc[1], color="g")
25      plt.xlabel('x1')
26      plt.ylabel('x2')
27
28      plt.show()

```